总体思路

核心信息就一句话：**在 linear model 的约束下，这个数据集能做的因果分析远比"跑个 Elastic Net + OVB"要深得多**，关键是三样东西——参与者固定效应、分组交叉验证、DML with Lasso。

数据层面的几个坑

数据规模：8378 行（每行是一次 4 分钟速配），约 552 个参与者（277 男 / 274 女），21 个 wave，哥伦比亚大学 2002-2004 年收集的。

最致命的坑——Wave 6-9 的量表不一致：Wave 1-5 和 10-21 用的是 100 分分配（6 个特质加起来必须等于 100），但 **Wave 6-9 用的是每个特质独立 1-10 打分，不受加总约束**。这两种完全不可比。大多数论文直接把 6-9 剔除掉，你们也应该这么做，然后在稳健性检验里加一个"保留 6-9 并归一化"的版本做对照。

嵌套结构：每个人给 10-22 个对象打分，所以同一个 `iid`（参与者 id）会在数据里出现很多次。这件事对后面所有分析都有连锁影响。

其他小坑：`income` 是带逗号的字符串要转数值；`field` 用 `field_cd`（编码）而不是原文本字段；有些人的 100 分分配加起来不等于 100 要重新归一化；Wave 5 用的是本科生不是研究生；Wave 12 有 50% 配额限制。

文献基准——对齐 Fisman 原论文的做法

有个**关键认知纠正**：Fisman et al. (2006, QJE) 原论文用的**不是** conditional logit，而是**带参与者固定效应的线性概率模型（LPM）+ partner 层面聚类标准误**。也就是说，你们如果用 LPM + FE，其实是在**原样复现顶刊方法**，完全站得住脚，不用担心课程要求"只能用线性模型"——Fisman 自己就是这么做的。

他们的核心结果：男生对颜值的系数是 0.140，女生是 0.119，差距显著但不大。**但是** Eastwick & Finkel (2008, JPSP) 在 Northwestern 做了同类实验，发现男女对颜值的权重**没有显著差异**。这个争议正好可以写进你们的讨论——说明晕轮效应造成的共线性让"哪个特质真正重要"这件事本身就很难识别，你们的项目就是在处理这个难题。

方法论深度——在线性模型内能做什么

第一个必须修的 bug：交叉验证有信息泄漏

这是最重要的一条。因为每个人有 10-22 行数据，**普通 k-fold CV 会把同一个人的数据同时放进训练集和测试集**，模型在训练时学到了"这个人普遍比较挑剔"这种个人特征，然后去"预测"同一个人的其他决定——CV 分数会被严重高估，调出来的 α 和 l1_ratio 都是错的。

修复方法：用 `GroupKFold(n_splits=5)` 并把 `iid` 作为 `groups` 传进去，保证同一个人的所有数据要么全在训练集，要么全在测试集。

注意一个技术细节：`ElasticNetCV` 的内部 CV 不支持传 `groups`，所以你们要么用 `GridSearchCV + ElasticNet` 组合（`GridSearchCV.fit()` 支持 `groups` 参数），要么手动把 `GroupKFold.split()` 的结果转成 list 传给 `cv` 参数。**推荐前者**，更规范。

这本身就是一个可以写进报告的发现：对比 naive k-fold 和 GroupKFold 下选出来的超参数和 CV 分数差距，差距越大说明泄漏越严重，这件事就是方法论贡献。

正则化方法的深化（都在线性模型范围内）

1. **Adaptive Lasso (Zou 2006)**：比普通 Lasso 多一步——先用 Ridge 跑一遍得到初始系数 $\hat{\beta}^{Ridge}$，然后构造权重 $w_j = 1/|\hat{\beta}_j^{Ridge}|^\gamma$，再对加权后的特征跑 Lasso。它有 **oracle property**——随着样本量增大，能以概率 1 选出真实模型，这是普通 Lasso 没有的性质。没有现成的 pip 包，但自己实现只要 10 行代码。
2. **Stability Selection (Meinshausen-Bühlmann 2010)**：对数据做 100 次随机二次抽样，每次跑 Lasso，统计每个变量被选中的频率。阈值通常设 0.6。这能回答"哪些变量是真正稳定被选中的"。有 `stability-selection` 这个 scikit-learn-contrib 包。画出来的 stability path 图会显示 `attr` 在几乎所有 λ 下都是 100% 被选中，`amb` 可能在 20% 左右晃——这张图本身就非常有说服力。
3. **Post-Lasso OLS**：Lasso 选完变量之后，在选中的变量上重新跑一个没有惩罚项的 OLS。这样既享受了 Lasso 的变量选择，又避免了 Lasso 系数的收缩偏差。你们算"真实权重"时应该用 Post-Lasso OLS 的系数而不是 Lasso 本身的系数，更可信。

因变量处理——LPM 就是对的

别被"binary outcome 必须用 logit"的直觉带跑。**在应用经济学里 OLS 跑二元因变量（LPM）是标准做法**，系数直接就是概率变化（边际效应），特别好解释。唯一要注意的是用 **heteroskedasticity-robust SE 或 cluster-robust SE**。Fisman 原论文也是这么做的，你们完全不用绕弯。

核心升级：参与者固定效应（FE）

在 LPM 里加上 `iid` 的固定效应（也就是给每个参与者一个 dummy），所有系数就变成了"同一个人内部的对比"——也就是说：

> "当参与者 i 觉得 A 比 B 颜值高 1 分，且在真诚、聪明、有趣等评分都相同的情况下，i 对 A 说 yes 的概率比对 B 高多少？"

这个估计自动控制了**所有不随时间变化的参与者特征**：本人颜值、年龄、种族、专业、收入、性格、挑剔程度、当晚心情——全部吸收进固定效应里，你甚至不用测量这些变量。

这一下就把分析从"横截面相关性"升级到了**within-person 的因果识别**，是质的飞跃。技术上用 `linearmodels` 的 `PanelOLS`，index 设成 `(iid, order)`，加 `entity_effects=True`，然后 `cov_type='clustered', cluster_entity=True` 做聚类标准误。

进阶版：再加一层 partner 固定效应（双向 FE，类似 AKM 模型），连 partner 的固有魅力也控制掉，剩下的识别来自配对特异的残差。这个对课程项目来说算是"加分项"，做出来很亮眼。

从 OVB 到 DML 的桥梁：Frisch-Waugh-Lovell 定理

原来的 OVB 分析（短回归 vs 长回归，$\hat{\alpha}_1 = \hat{\beta}_1 + \hat{\beta}_2\hat{\gamma}$）其实是一个**完美的 pedagogical setup**，可以自然过渡到 FWL 定理，再过渡到 DML。逻辑链是这样的：

OVB：短回归系数 = 长回归系数 + 偏差项。这是你们已经有的。

FWL 定理：长回归里 `attr` 的系数，等于"用其他变量回归 `dec` 的残差"对"用其他变量回归 `attr` 的残差"做简单回归得到的系数。也就是说，多元回归本质上是"先把其他变量的影响剥掉，再看剩下的关系"。

DML (Chernozhukov et al. 2018, Econometrica)：FWL 里"剥掉其他变量"这一步，OLS 只能剥线性部分。如果换成用 **Lasso** 来剥，就能处理高维控制变量，还保证因果估计的一致性和渐进正态性。**关键是——Lasso 是线性模型，所以 DML with Lasso 完全在你们的课程约束内。**

用 `DoubleML` 这个 Python 包就 5 行代码：outcome 是 `dec`，treatment 是 `attr`，controls 放其他所有变量（可以放很多，Lasso 会自己选），nuisance learner 设 `LassoCV()`，cross-fitting 自动做。输出一个 debiased 的颜值因果系数 + 有效置信区间。这是 2018 年 Econometrica 的方法，放在本科/硕士课程项目里是非常前沿的。

敏感性分析——给因果故事一个可信的收尾

Cinelli & Hazlett (2020, JRSS-B) 的 Sensemakr：这是 OVB 的现代化升级。核心输出是 **Robustness Value (RV)**——"一个被遗漏的混淆变量需要有多强（用和 treatment 及 outcome 的 partial R^2 衡量），才能把你的估计效应完全抹平"。比如如果 RV = 0.15，意思是需要一个能同时解释 attr 和 dec 残差中至少 15% 方差的变量才能推翻结论。还能和已观测的变量做 benchmark——"一个比性别强 3 倍的混淆变量仍然不足以推翻晕轮效应"。Python 包是 `PySensemakr`，能画出漂亮的等高线图。

Oster (2019) bounds 作为次要的稳健性检查。没有现成 Python 包，但公式简单，10 行自己写。

推荐的五幕结构

把原来的 4 幕扩成了 5 幕，叙事不变，每一幕都更硬：

第一幕 "证人陈述"——EDA 和声称-实际落差 清洗数据（剔除 Wave 6-9 并说明理由），画 6 个特质的相关系数热力图直接把共线性摆出来，然后对比声称权重 vs 简单回归权重，引出"认知共线性"概念。

第二幕 "审讯"——带正确 CV 的正则化揭示真实偏好 跑 Elastic Net 但**用 GroupKFold**，对比 naive CV 和 GroupKFold 的差距作为方法论发现。跑 Adaptive Lasso，跑 Stability Selection 并画 stability path，再用 Post-Lasso OLS 得到无偏系数。用参与者级别的 bootstrap 算权重的置信区间（注意 bootstrap 时要**按参与者重抽样**而不是按行）。

第三幕 "控制法庭"——固定效应和组内识别 用 PanelOLS 加参与者固定效应，对比 pooled OLS 和 FE 的系数变化，解释哪些混淆被吸收了。可选加 partner 固定效应做双向 FE。然后做异质性分析：`attr × gender`、`attr × attr1_1`（"嘴上说不看重颜值的人，晕轮效应是不是反而更强？"——这个如果显著会是很有爆点的发现）、`attr × samerace`。

第四幕 "上诉"——OVB、DML、敏感性分析 从你们原来的 OVB 分解开始，桥接到 FWL 定理，再桥接到 DML with Lasso。用 DoubleML 包算一个 debiased 的颜值因果效应，和 pooled OLS、FE 的结果并排对比。用 PySensemakr 算 RV 并画等高线图，benchmark 到性别、种族等观测变量上。Oster bounds 作为次要检查。

第五幕 "判决"——综合与稳健性 一张总表把所有方法的系数、标准误、识别策略并排列。子样本检验：男女分组、剔除 Wave 5 本科生、剔除 Wave 12 配额限制。Leave-one-wave-out CV。最后升华到——人无法准确内省自己的择偶决定，晕轮效应造成系统性共线性让朴素回归误导人，但 within-person 识别和敏感性分析证实颜值真的在主导决定，不只是统计伪像。

Python 包清单

几个要安装的：`pip install linearmodels DoubleML PySensemakr stability-selection`，外加 scikit-learn 和 statsmodels。报告里每个方法我都给了可以直接跑的代码片段。

这个项目为什么能在研究生课程里脱颖而出

三件事让它超越普通课程项目：

1. **GroupKFold**——Kaggle 上绝大多数这个数据集的分析都忽略了聚类结构，你们做对了就是相对 baseline 的真实方法论贡献。
2. **参与者固定效应**——这是 Fisman 原论文的识别策略，等于你们在复现 QJE 论文的 identification strategy。
3. **DML with Lasso**——2018 年 Econometrica 的方法，大多数统计研究生还没学过，展示前沿因果推断的同时严格守在线性模型范围内。