Speed Dating Halo Effect — 项目交接文档

> **这份文档的目的**：即使是一个完全没有上下文的 Claude 实例，或者几周后失忆的我自己，读完这份文档也能直接接着干，不需要重新做决策。
>
> **课程**：UC Berkeley STAT 230A (Linear Models Extended)
> **小组成员**：Hanzheng Chen (hzchen@berkeley.edu) + Linsong Ge
> **工具**：Python（pandas, sklearn, statsmodels, linearmodels, PySensemakr）
> **约束**：线性模型为主（LPM / OLS / GLS / 惩罚线性回归）；课程允许 logistic 但主分析选择 LPM（理由见第 5.1 节）

---

1. 项目一句话总结

用 Columbia Speed Dating 数据（Fisman et al. 2006），通过"正则化回归 + 固定效应 + 敏感性分析"的组合，证明**人们声称的择偶偏好和实际择偶行为严重不符，并且这种不符源于晕轮效应造成的认知共线性**——看到漂亮的人会连带觉得对方真诚、聪明、有趣。

2. 叙事主线与 Hypothesis

每个 Stage 必须对应一个**可证伪的 hypothesis**和**具体的度量指标**（教授反馈要求）。

Stage	Hypothesis	核心度量	方法
1. 证人陈述	H1: 声称权重中 attr 的比例显著低于实际决策揭示的 attr 权重	stated% vs revealed% 的差距	EDA + 相关系数热力图 + Baseline LPM
2. 审讯	H2: 在扩展特征集（40+变量）中，正则化后仅有 attr 和少数变量被稳定选中	Stability Selection 选中概率	Elastic Net + GroupKFold + Adaptive Lasso + Stability Selection
3. 控制法庭	H3: 控制参与者 FE 后，attr 仍然是最大且显著的系数	Pooled OLS vs FE 系数对比表	LPM + 参与者固定效应（PanelOLS）
4. 上诉	H4: 所有非 attr 特质的系数在加入 attr 后显著萎缩（晕轮的数学证据）	短/长回归系数萎缩比例	OVB 分解（全部 5 个非 attr 特质）+ Cinelli-Hazlett Sensemakr
5. 判决	结果在各种切片下都稳健	attr 系数在多 specification 下的稳定性	子样本、leave-one-wave-out、logistic robustness

核心度量（贯穿全项目）：各特质系数在不同 specification 下的变化幅度。晕轮效应的直接测量 = 加了 attr 后其他特质系数的萎缩量。

3. 核心研究问题

1. **声称偏好 vs 实际偏好**：参与者赛前声称的特质权重，和他们实际 yes/no 决定揭示的权重，差距有多大?
2. **颜值的因果主导性**：在控制了晕轮造成的共线性和参与者异质性之后，颜值是否真的是决定性因素，还是统计假象?

4. 数据集关键事实（已验证，不要重新考证）

- **来源**：Fisman, Iyengar, Kamenica, Simonson 2002-2004 在 Columbia 收集
- **下载**：Kaggle `annavictoria/speed-dating-experiment`，文件名 `Speed Dating Data.csv`（注意：另一个 `speeddating.csv` 是预处理版本，**没有 iid/pid**，不能用于 Stage 2-3）
- **加载**：`pd.read_csv('Speed Dating Data.csv', encoding='latin-1')`（必须指定 encoding）
- **规模**：8378 行 × 195 列；551 个参与者；21 个 wave
- **嵌套结构**：每个人给 5-22 个对象打分（中位数 16 次）。`iid` = 参与者 id，`pid` = 对方 id
- **接受率**：42.0%（dec=1 有 3518 次）
- **匹配率**：16.5%（match=1 有 1380 次）
- **性别**：gender=0 女（4184 行），gender=1 男（4194 行）

变量完整地图（195 列分组）

可直接用于建模的变量（约 50 个）：

类别	变量	数量	说明	缺失率
因变量	`dec`, `dec_o`, `match`	3	本人决定/对方决定/互相匹配	0%
核心打分	`attr, sinc, intel, fun, amb, shar`	6	约会后给对方的 1-10 打分	2-13%
声称偏好	`attr1_1 ... shar1_1`	6	赛前 100 分分配	~1%
自我评价	`attr3_1, sinc3_1, fun3_1, intel3_1, amb3_1`	5	"你觉得自己有多好看/真诚/聪明..." (1-10)	~1%
对方给	`attr_o, sinc_o, intel_o, fun_o, amb_o, shar_o`	6	对方给我的打	2-

我打分			分	13%
对方声称偏好	`pf_o_att ... pf_o_sha`	6	对方赛前的100 分分配	~1%
17个兴趣	`sports, tvsports, exercise, dining, museums, art, hiking, gaming, clubbing, reading, tv, theater, movies, concerts, music, shopping, yoga`	17	自评各类兴趣1-10	~1%
匹配度	`int_corr, samerace`	2	兴趣相关度、是否同族	0-2%
人口学	`age, gender, race, field_cd, income, imprace, imprelig, goal, date, go_out`	10	基本信息+约会习惯	0-49%
元评价	`like, prob, met, exphappy`	4	总体喜欢度/猜对方喜欢概率/之前见过没/期望快乐度	1-5%
实验结构	`iid, pid, wave, order, round, condtn`	6	参与者/对方ID、波次、顺序等	0%

应丢弃的变量（约 140 个）： 带 `_2`、`_3`、`_s` 后缀的 follow-up 问卷（缺失 30-80%）；`undergra`（41%）、`mn_sat`（63%）、`tuition`（57%）、`expnum`（79%）等高缺失列。

相关矩阵（晕轮效应的直接证据，已验证）

```
        attr   sinc  intel    fun    amb   shar
attr   1.000  0.400  0.391  0.586  0.359  0.480
sinc   0.400  1.000  0.658  0.492  0.457  0.398
intel  0.391  0.658  1.000  0.494  0.627  0.400
fun    0.586  0.492  0.494  1.000  0.490  0.618
amb    0.359  0.457  0.627  0.490  1.000  0.433
shar   0.480  0.398  0.400  0.618  0.433  1.000
```

所有 off-diagonal > 0.35，attr-fun = 0.586，sinc-intel = 0.658。

Baseline 发现（已验证的数字，可作为 benchmark）

声称 vs 实际权重（全体，排除 Wave 6-9）：

```
特质    | 声称%  | 实际%  | 差距        | 解读
attr    | 24.1% | 39.0% | +14.9% ↑↑ | 颜值被严重低报
sinc    | 17.1% |  8.7% |  -8.4% ↓  | 真诚被严重高报
intel   | 20.4% |  3.9% | -16.5% ↓↓ | 智商几乎不影响决定
fun     | 17.3% | 17.2% |  -0.1% ≈  | 有趣：说到做到
amb     |  9.9% | 10.6% |  +0.7% ≈  | 野心：说到做到
shar    | 11.2% | 20.6% |  +9.4% ↑  | 共同爱好比想象中重要
```

按性别： 男生声称 attr 29.3% → 实际 44.7%（+15.4）；女生声称 attr 18.8% → 实际 28.8%（+10.0）。两性都在低报颜值依赖，男生差距更大。

⚠️ **sinc 和 intel 的 raw OLS 系数是负的**（sinc = -0.0193, intel = +0.0087）。这是共线性造成的——attr 太强把它们的正效应吸走了。这就是 Stage 2-3 存在的理由。

⚠️ 已决定的数据清洗选择（不要推翻）

1. **Wave 6-9 主分析中剔除**。已验证：Wave 1 声称总和 = 100.0（std=0），Wave 6 = 90.0（std=31.6）。保留做 robustness check。
2. **Follow-up survey 变量（*2/3/_s* 后缀）全部丢弃**。缺失率 30-80%。
3. **Income 列处理**：带逗号字符串，49% 缺失，仅在扩展模型中使用。

5. 方法论关键决策（不要推翻）

5.1 为什么主分析用 LPM 而不是 Logistic?

课程**允许**使用 logistic regression，我们选择 LPM 是**主动的方法论选择**：

- **关键理由 1**：参与者 FE（Stage 3 核心）在 LPM 里直接加 entity dummy。Logistic 需要 conditional logit 来避免 incidental parameters problem，Python `statsmodels` 没有标准接口
- **关键理由 2**：Sensemakr（Stage 4 核心）只有 OLS 框架的实现
- **关键理由 3**：LPM 系数直接是边际概率变化，和"权重"叙事天然对应
- Fisman et al. 2006 原论文也用 LPM
- Logistic 在 Stage 5 作为 robustness check

如果教授问"为什么不用 logistic"："课程允许，我们 Stage 5 也做了 robustness check。主分析用 LPM 是因为 Stage 3 的参与者 FE 在 LPM 里直接加 entity effects，logistic 要 conditional logit 来避免 incidental parameters problem；Stage 4 的 Sensemakr 只有 OLS 实现。不是被约束逼的，是主动选择。"

5.2 为什么 CV 必须用 GroupKFold?

- 每个参与者有 5-22 行数据（中位数 16）
- 普通 KFold 信息泄漏 → CV 分数高估 → 调出来的 α 错误
- **必须**用 `GroupKFold(n_splits=5).split(X, y, groups=df['iid'])`

- `ElasticNetCV` 不支持 groups → 用 `GridSearchCV + ElasticNet`

5.3 为什么要加参与者固定效应?

- **整个项目最重要的因果识别策略**
- 系数只从"同一个人对不同对象的打分差异"里识别
- 自动控制所有 time-invariant 个人特征
- 用 `linearmodels.PanelOLS`，index 设成 `(iid, order)`
- 这是 Fisman et al. 2006 的 identification strategy

5.4 为什么 Stage 2 需要扩展特征集? （教授反馈）

教授批评：只有 6 个特质变量，p=6 远小于 n=8000，正则化缺乏动机。扩展到 40+：

类别	变量	数量
核心打分	`attr, sinc, intel, fun, amb, shar`	6
自我评价	`attr3_1, sinc3_1, fun3_1, intel3_1, amb3_1`	5
对方给我打分	`attr_o, sinc_o, intel_o, fun_o, amb_o, shar_o`	6
17 个兴趣	`sports ... yoga`	17
匹配度	`int_corr, samerace, age_diff`	3
人口学	`age, gender, race dummies, field_cd`	5+
约会偏好	`imprace, imprelig, goal, date, go_out`	5
总计		**~47**

6. Python 包清单

```
pip install pandas numpy scipy scikit-learn statsmodels linearmodels PySensemakr
stability-selection matplotlib seaborn pyarrow
```

7. 项目文件组织

```
speed-dating-halo/
├── data/
│   ├── raw/Speed Dating Data.csv          # 原始 195 列（有 iid/pid）⚠️ 用这个
│   └── clean/cleaned.parquet
├── notebooks/
│   ├── 00_data_cleaning.ipynb
│   ├── 01_stage1_eda_baseline.ipynb
│   ├── 02_stage2_regularization.ipynb
│   ├── 03_stage3_fixed_effects.ipynb
```

```
│   ├── 04_stage4_ovb_sensemakr.ipynb
│   └── 05_stage5_robustness.ipynb
├── figures/
├── report/
└── PROJECT_HANDOFF.md  (本文件)
```

⚠️ **不要使用 `speeddating.csv`（123 列预处理版本）**，它没有 iid/pid。

8. 每个 Stage 的执行清单

Stage 0: 数据清洗

```
import pandas as pd
df = pd.read_csv('data/raw/Speed Dating Data.csv', encoding='latin-1')
df_main = df[~df['wave'].isin([6,7,8,9])].copy()
df_main['income'] =
df_main['income'].astype(str).str.replace(',','').replace('nan',None).astype(float)
core_vars = ['dec','attr','sinc','intel','fun','amb','shar','iid','pid','wave','gender']
df_main = df_main.dropna(subset=core_vars)
stated_cols = ['attr1_1','sinc1_1','intel1_1','fun1_1','amb1_1','shar1_1']
row_sums = df_main[stated_cols].sum(axis=1)
df_main[stated_cols] = df_main[stated_cols].div(row_sums, axis=0) * 100
df_main['age_diff'] = (df_main['age'] - df_main['age_o']).abs()
df_main.to_parquet('data/clean/cleaned.parquet')
```

Stage 1: EDA + Baseline（H1）

1. 按 gender 算声称权重 → 雷达图/柱状图
2. 6 打分相关矩阵 → 热力图（晕轮视觉证据）
3. Baseline LPM with cluster SE → revealed weights
4. 并排柱状图 stated vs revealed（**核心图**）
5. 按性别拆开

Stage 2: 正则化（H2）

1. 扩展特征集到 40+（见 5.4 节）
2. naive KFold vs GroupKFold 对比
3. Elastic Net → Adaptive Lasso → Stability Selection
4. Post-Lasso OLS
5. Bootstrap CI（按 iid 重抽样）

Stage 3: 固定效应（H3）

```
from linearmodels.panel import PanelOLS
df_panel = df_main.set_index(['iid', 'order'])
mod = PanelOLS.from_formula('dec ~ attr + sinc + intel + fun + amb + shar +
EntityEffects', data=df_panel)
res = mod.fit(cov_type='clustered', cluster_entity=True)
```

报告：Pooled OLS vs FE 系数对比表 + 异质性交互项（attr×gender, attr×attr1_1）

Stage 4: OVB + Sensemakr（H4）

对全部 5 个非 attr 特质做 OVB（不只是 sinc）：

```
for trait in ['sinc', 'intel', 'fun', 'amb', 'shar']:
    short = smf.ols(f'dec ~ {trait}', data=df_main).fit()
    long_ = smf.ols(f'dec ~ {trait} + attr', data=df_main).fit()
    # 记录萎缩比例
```

Sensemakr contour plot + Robustness Value

Stage 5: 稳健性

保留 Wave 6-9 重跑；男女分样本；leave-one-wave-out；logistic robustness check；总表

9. 已搞清楚的问题和答案

Q: 为什么用 LPM? → 见 5.1 节。课程允许 logistic，但 LPM 配合 FE 和 Sensemakr 更好。

Q: 为什么只有 6 个变量就做正则化? → 不再只有 6 个，扩展到 40+（见 5.4 节）。

Q: OVB 为什么只用 sinc? → 不再只用 sinc，全部 5 个非 attr 特质都做。

Q: logistic 下 OVB 公式还成立吗? → 不精确成立。主分析用 LPM（精确成立）。

Q: 两个 CSV 哪个对? → 用 `Speed Dating Data.csv`（195 列有 iid/pid），不用 `speeddating.csv`（123 列无 iid/pid）。

10. 踩坑记录（持续更新）

- `ElasticNetCV` 不能传 `groups` → 用 `GridSearchCV + ElasticNet`
- `PanelOLS` 需要 MultiIndex → `.set_index(['iid','order'])`
- `PySensemakr` 参数名要和 statsmodels 系数名完全一致
- income 是带逗号字符串，49% 缺失
- `speeddating.csv` 没有 iid/pid，不能用
- Wave 7 声称总和恰好 = 100 但它是独立 1-10 打分，不要被骗

11. 教授/TA 反馈记录

1. **每个 Stage 必须有 hypothesis 和度量** → 已更新到第 2 节

2. **Stage 2：6 个变量正则化缺乏动机** → 扩展到 40+（见 5.4 节）
3. **Stage 3：明确报告哪些数字** → Pooled OLS vs FE 系数对比表
4. **Stage 4：OVB 对所有非 attr 变量做** → 已更新
5. **Logistic 下 OVB 公式不精确** → 主分析用 LPM

12. 当前进度

当前状态：数据探索完成，baseline 数字已验证，教授反馈已消化。下一步写 Stage 0。

- [ ] Stage 0 数据清洗
- [ ] Stage 1 EDA
- [ ] Stage 2 正则化
- [ ] Stage 3 固定效应
- [ ] Stage 4 OVB + Sensemakr
- [ ] Stage 5 稳健性
- [ ] 写报告

13. 核心文献

1. **Fisman et al. (2006)** *QJE* — 原论文。benchmark：attr 系数男 ~0.140 女 ~0.119；模型 = LPM + 参与者 FE + partner 聚类 SE
2. **Cinelli & Hazlett (2020)** *JRSS-B* — Sensemakr
3. **Zou (2006)** *JASA* — Adaptive Lasso
4. **Meinshausen & Bühlmann (2010)** *JRSS-B* — Stability Selection
5. **Wooldridge** Ch. 10 — FE 理论
6. **Eastwick & Finkel (2008)** *JPSP* — 同类实验发现男女对颜值权重无显著差异，与 Fisman 矛盾

不要推翻已定决策。 答案在第 4、5、9、11 节。这些决策吸收了教授反馈后确定的。